TP OpenMP – Méthode de Newton

1. OpenMP

OpenMP est une bibliothèque qui facilite l'écriture des programmes parallèles multi-threading pour des architectures parallèles à mémoire partagée. OpenMP fournit des fonctions de gestion de threads (ex. `omp_get_num_threads`) et des directives de compilation (`#pragma`) qui permet la création et la gestion des régions parallèles à partir d'un programme séquentiel.
L'exécution d'un programme OpenMP entraîne l'exécution simultanée de plusieurs threads. Les threads d'un même programme peuvent avoir des variables partagées (i.e. une seule copie mémoire par variable) ou des variables privées (le même nom, mais une copie mémoire par variable et par thread). La gestion des variables partagées / privées est primordiale pour la justesse des résultats du programme et de sa performance. La performance du programme est aussi grandement affectée par la gestion de régions parallèles.

Les versions récentes de **gcc** intègrent la bibliothèque OpenMP. La version d'OpenMP supportée dépendant de la version de **gcc**. L'utilisation de l'option **-fopenmp** permet à **gcc** de compiler vos programmes OpenMP.

2. **Prise en main** : éditer le programme `hello_omp.c` suivant

```
#include <stdio.h>
#include <stdlib.h>
#include <sched.h>
#include <unistd.h>
#include "omp.h"

int main()
{
   int tid=-1;  char hostname[1024];

   gethostname(hostname, 1024]);
   printf("Before PARALLEL REGION TID %d: There are %d threads on CPU %d of %s\n\n",
          omp_get_thread_num(), omp_get_num_threads(), sched_getcpu(), hostname) ;

   #pragma omp parallel num_threads(4) firstprivate(tid)
   {
       tid=omp_get_thread_num();
       if (!tid)
           printf("In the PARALLEL REGION TID %d: There are %d threads in process\n",
                  omp_get_thread_num(), omp_get_num_threads());
       printf("Hello World from TID %d / %d on CPU %d of %s!\n\n",
                tid, omp_get_num_threads(), sched_getcpu(), hostname);
   }

   printf("After PARALLEL REGION TID %d: There are %d threads\n\n" ,
          tid, omp_get_num_threads()) ;

   return EXIT_SUCCESS ;
}
```

- Exécution directe du programme **hello_omp** : **$ ./ hello_omp**
- Interpréter le résultat d'exécution : qui (thread) exécute quoi (instruction) ?
- Modifier le nombre de threads en utilisant l'une des méthodes suivantes :
  - la clause `num_threads` de `#pragma omp parallel`
  - la variable d'environnement OMP_NUM_THREADS

- la fonction `void omp_set_num_threads(int num_threads) ;`

- Si on remplace la clause `firstprivate` par `private`, que peut-il se passer ?
  Pour constater le changement, commenter la ligne `tid=omp_get_thread_num();` et re-exécuter plusieurs fois le programme.
- Supprimer la clause `private`, refaire les exécutions, que constatez-vous ?

3. Génération parallèle d'image fractale (Méthode de Newton)

Etant donnée une fonction *f(x) = x^3 – 1, x* est une variable complexe, le calcul des racines de *f(x)* peut être effectué par la méthode de Newton :

$$\begin{cases} x_{n+1} = x_n + \dfrac{f(x_n)}{f'(x_n)}, n \geq 0 \\ x_0 \text{ est un nombre complexe quelconque} \end{cases}$$

Pour chaque valeur x_0, la méthode de Newton converge vers l'une des 3 racines de *f(x)*.
Nous allons utiliser cette propriété dans la génération d'image fractale définie sur le domaine *[Xmin, Xmax]* x *[Ymin, Ymax]*.

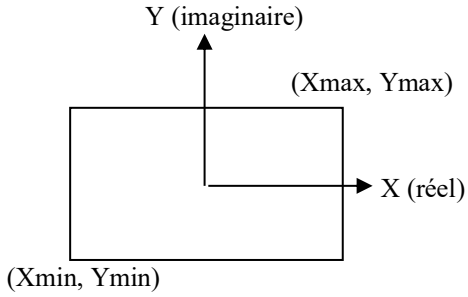

La génération d'image correspond à l'application de la méthode à la fonction f(x), en utilisant chaque point du domaine comme la valeur de x_0. Nous affectons la couleur C_1 (resp. C_2 ou C_3) à un point *P* du domaine, si la méthode de Newton converge vers la racine 1 (resp. la racine 2 ou 3) avec x_0=les coordonnées du *P*.

3.1. Récupérer le programme séquentiel dans un nouveau répertoire – Compiler – Exécuter

3.2. Enlever la ligne « `xhost -` » de votre `.bashrc` s'il y en a.

3.3. 1ère parallélization : Le calcul d'image contient 2 boucles imbriquées. Paralléliser ce calcul à l'aide de la directive OpenMP compacte « #pragma omp parallel for »; La parallélization de laquelle boucle permet d'avoir une meilleure performance ?

Attention :
- Pas d'{ après `#pragma omp parallel for` ou `#pragma omp for`, la ligne suivante doit être une boucle `for`.
- Le nombre de threads dépend non seulement de `num_threads` mais aussi de `chunk_size`.
- Faites attention aux **variables partagées/privées**, à **l'accès de variables partagées** et aux **instructions non préemptives** (qui implique l'**utilisation de section critique**).

N'oubliez pas de modifier le makefile pour la compilation (ajout de l'option `-fopenmp`).

3.4. Mesurer la performance de la 1ère parallélization en variant le nombre de threads et la taille de l'image, analyser les résultats obtenus. ! on mesure uniquement le temps de calcul d'une image. Exemple : nombre de threads = 1, 2, 4, 8, 16, 32… ; taille d'image = 1024x1024, 1024x1536, 1536x2048, 2048x2560…

3.5. Que constatez-vous après l'analyse de performance ? Quelle modification peut-on apporter afin d'améliorer la performance du programme parallèle ?

3.6. Ajouter la clause « schedule(static, chunk_size) » et faites varier la taille de bloc traité en une fois par un thread. Refaire la mesure de performance avec une taille de l'image donnée et en variant le nombre de threads.

3.7. Tester l'ordonnancement et la répartition de charge avec « schedule(dynamic) ». Que constatez-vous ?

Annexe : Evaluation de performance d'un programme parallèle

La performance d'un programme parallèle s'évalue en comparant le temps d'exécution parallèle au temps d'exécution séquentielle. L'évaluation commence par la mesure du temps écoulé entre le début du 1er thread (ou processus) et la fin du dernier thread (ou processus) du programme.

On mesure le temps d'exécution en variant le nombre de threads (ou processus) utilisés et la taille du problème. Plusieurs mesures sont à réalisées pour chaque couple (nombre de threads, taille du problème). La moyenne de ces mesures sera considérée comme le temps d'exécution de ce cas.

L'ensemble de mesures est alors stocké dans un tableau. A partir de ces mesures, on peut tracer les courbes du temps d'exécution selon la taille et/ou selon le nombre threads. On peut aussi calculer le facteur d'accélération (speedup), l'efficacité du programme parallèle, etc.

Attention : les mesures doivent être effectuées sur le même nœud, sous les mêmes conditions. Elles peuvent être polluées si plusieurs threads (ou processus) s'exécutent simultanément sur un même core (ou socket / node). L'hyper-threading des cores est une des causes qui peut fausser la mesure du temps d'exécution. Il est désactivé sur le cluster. Bref, la condition de **turing** n'est pas idéale pour la mesure de performance d'un programme parallèle.

Il est important d'utiliser le contrôle de l'affinité des threads pour avoir des mesures stables. En OpenMP, vous pouvez utiliser les variables d'environnement OMP_PROC_BIND (=true) et OMP_PLACES (="{0},{4},{8},{12},{16},{20},{24},{28}") pour avoir 1 thread par core sur 8 cores du NUMA node 0 de **turing**. Cela évite qu'un thread soit affecté à des cores différents au cours d'une exécution. Vous pouvez ainsi manuellement éviter le hyperthreading.

Exemple :

Tableau 1: Le temps d'exécution d'un programme parallèle en fonction de la taille du problème et du nombre de threads employés

Nb_threads Taille	1	2	4	8	16
256	0,22	0,16	0,13	0,06	0,03
512	1,88	1,19	0,77	0,36	0,18
768	7,09	3,71	2,64	1,02	0,57
1024	16,29	8,24	6,35	2,36	1,27
1280	31,92	17,33	10,60	4,72	2,58
1536	60,50	36,28	22,07	9,52	5,01
1792	105,13	67,82	33,59	17,83	9,33
2048	158,88	105,99	64,40	28,90	15,17

Tableau 2 : Le speedup du programme en fonction du nombre de threads et de la taille du problème

Nb_threads Taille	1	2	4	8	16
512	1	1,58	2,43	5,15	10,21
1024	1	1,98	2,57	6,89	12,83
1536	1	1,67	2,74	6,36	12,08
2048	1	1,50	2,47	5,50	10,47

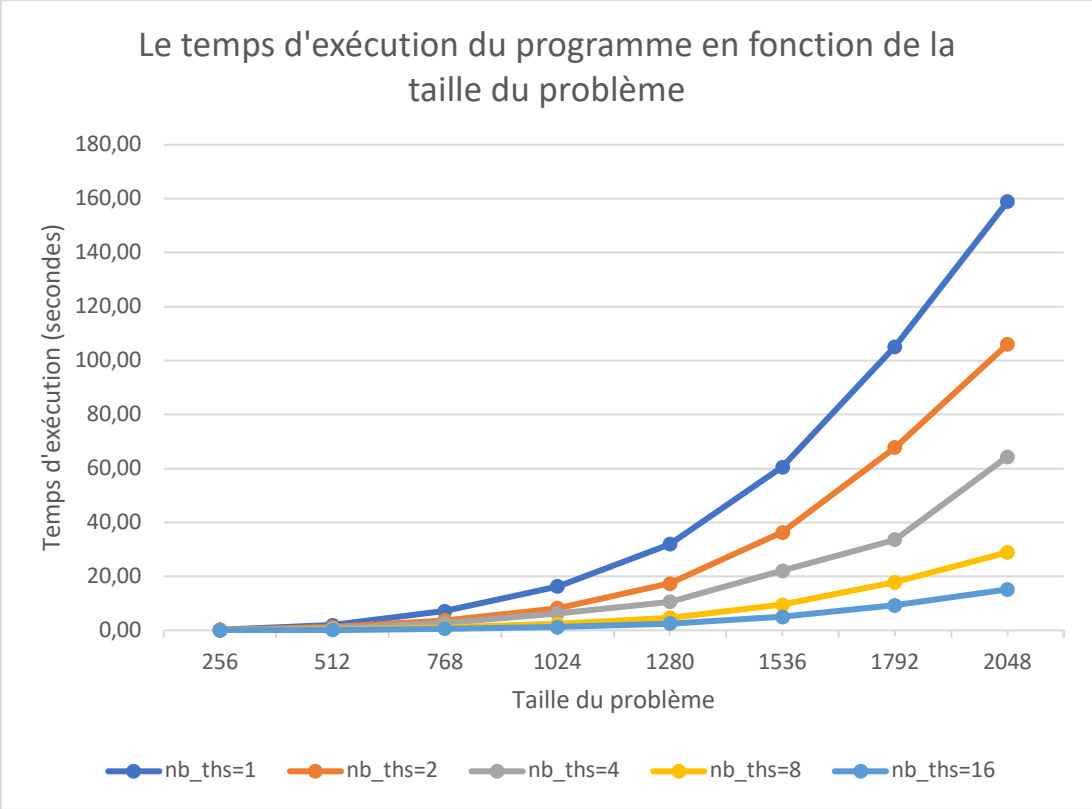

Figure 1 : L'évolution du temps d'exécution d'un programme parallèle en fonction de la taille du problème

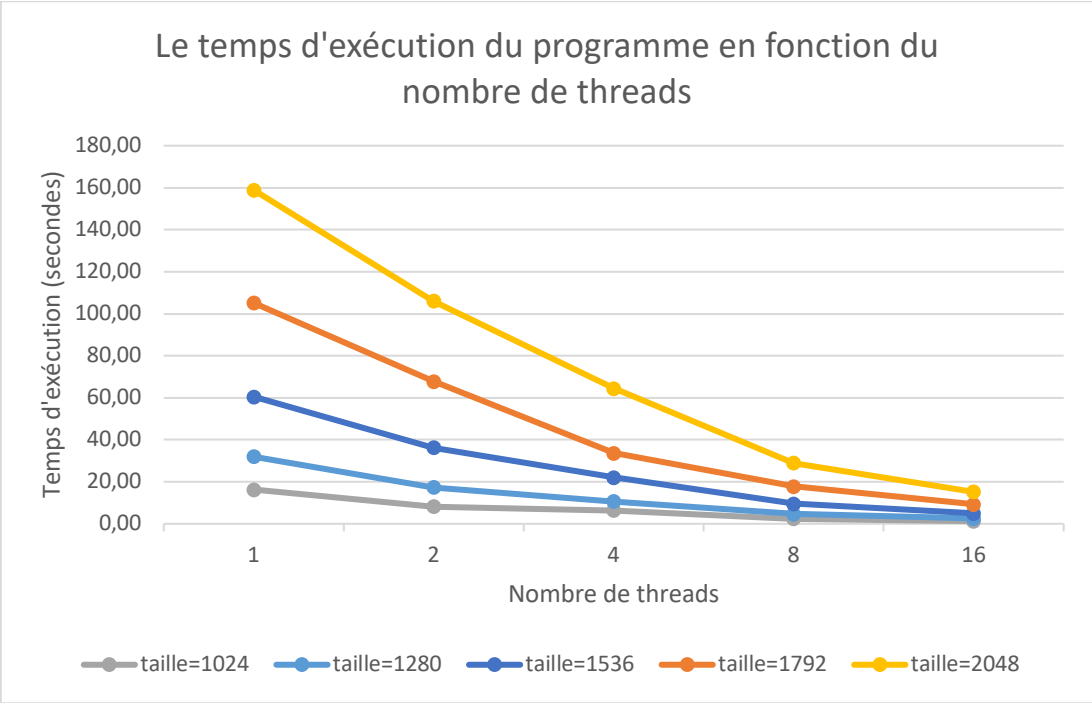

Figure 2 : L'évolution du temps d'exécution d'un programme parallèle en fonction du nombre de threads utilisés

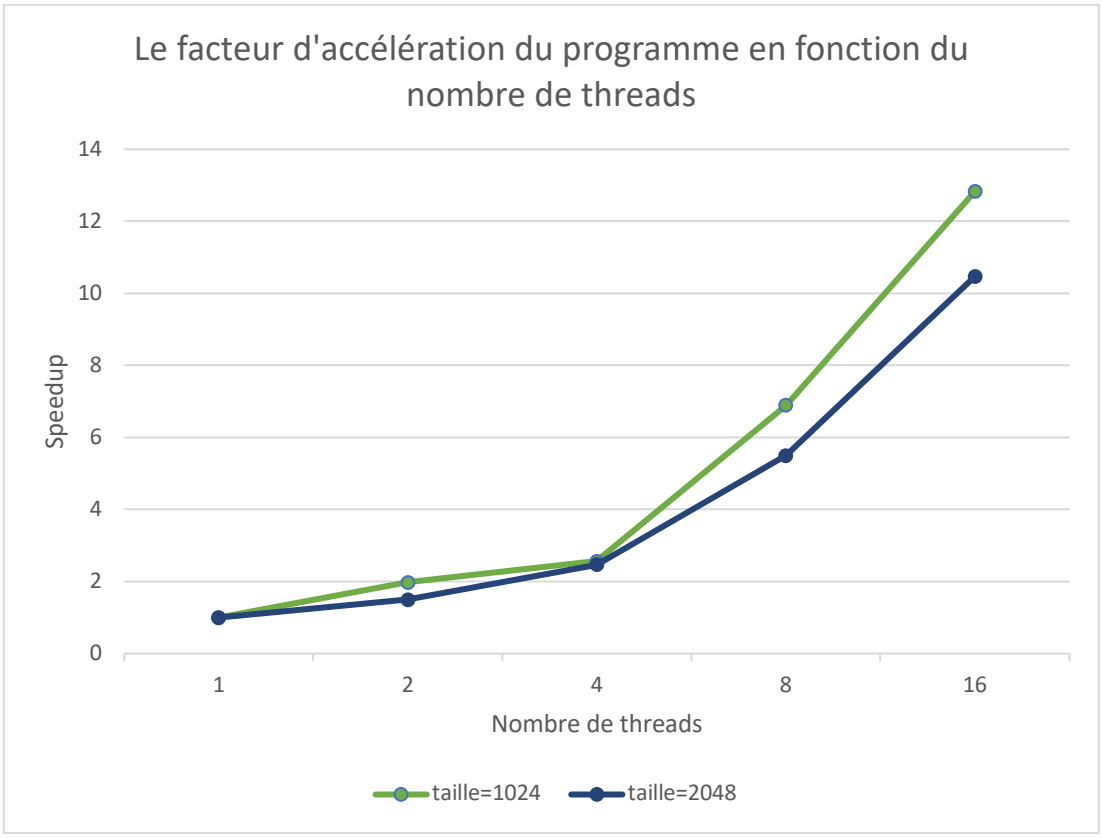

Figure 3 : Le facteur d'accélération du programme parallèle en fonction du nombre de threads utilisés pour la taille de matrice 1024x1024 et 2048x2048